

河北十座光伏电站 15 分钟级功率预测： 基线对比、机器学习方法评估与跨站迁移检验

徐敏纯 学号 3120260807425

2026 年 10 月 3 日

摘要

光伏出力随天气起伏，电网需提前知道下一刻能发多少电。本文使用河北十座光伏电站的公开数据集 PVOD[8, 9] (271968 条 15 分钟记录)，回答两个问题：复杂模型是否一定优于简单模型，以及如何更好地利用多站数据。

四种信息条件下比较朴素基线、线性回归、树模型与 LSTM：同时刻气象加历史观测时，线性回归的 MAE 最低 (1.4942%，较基线降 41.74%)，优于全部树模型——它能学到「出力 $\approx$ 上一刻出力」的恒等映射，树模型只能输出分段常数；换成预报气象则误差翻倍 (4.8725%)；LSTM 在四个设定上全部落后，最差比线性回归差 111.6%，耗时却高三千余倍。留一站交叉验证中，多站联合训练是三类模型共同的最优做法 (LightGBM 降 14.61%、XGBoost 降 4.11%、LSTM 降 36.15%)，预训练加微调只在可微的 LSTM 上有效 (18.01%)，直接搬用别站训好的模型则在三类模型上一律为负收益。

关键词：光伏功率预测；模型复杂度对比；恒等映射；皮尔逊相关分析；跨站迁移；留一站交叉验证

1 引言

随着光伏装机容量的快速增长，出力的间歇性与波动性给电网调度带来压力，短时功率预测因此成为新能源并网的必要环节 [1]。已有方法大致分三类：依据辐照度与组件温度推算出力的物理方法、依赖数值天气预报的统计方法，以及以随机森林、梯度提升树为代表的机器学习方法 [3, 6]。其中随机森林因对非线性关系拟合能力强、不易过拟合，在超短期预测中被广泛采用 [7]；以数值天气预报为输入的多种机器学习方法亦已有系统性横向对比 [4]。

已有研究多默认「预测时刻的气象观测已可获得」。但实际情形并不统一：有的电站配有站内气象站，能拿到当前时刻的实测辐照；有的只能拿到数值天气预报；还有的既无实时气象采集、也无预报接入，只能依据已经采集到的历史序列外推当前出力。这三种信息条件下，模型能发挥多大作用、又分别在哪些天气条件下失效，尚缺乏在同一条流水线上、用长时段实测数据做的对照。

另一个容易被忽略的前提是：绝大多数研究只针对单一电站建模，结论是否适用于同一数据集之外的其他电站，很少被检验。而新建电站往往只有几周数据，恰是最需要预测、又最缺数据的场景。若能借助已运行电站的数据改善本站预测，其工程价值不亚于换一个更好的算法。

综合以上，本文围绕两个研究问题展开。

研究问题一：复杂模型是否一定优于简单模型？在同一份数据、同一条时间切分下，把朴素基线（固定系数公式、Persistence）、线性回归、随机森林、梯度提升树、XGBoost、LightGBM 与 LSTM 放在一起比较，同时报告精度与训练耗时，看模型变复杂是否真的换来更低的误差。

研究问题二：如何更好地利用多个站点的数据进行预测？用留一站交叉验证检验「借用别站数据」能否改善本站预测，比较从零训练、预训练后微调、零样本迁移与多站联合训练四种做法，并分别用树模型与 LSTM 各做一遍，观察两类模型是否遵循同一条规律。

为回答这两个问题，本文把「气象信息可得性」设为控制变量，在四种信息条件下逐一复现：同时刻站内实测气象可得、同时刻仅有数值天气预报、仅历史观测可用、以及同时刻气象与历史观测兼有；再用特征重要性与特征消融解释模型到底依赖了什么，最后对一个更基础的疑问作出检验——所用数据集的目标列是否为真实计量值。全部实验在河北十座光伏电站的公开数据集 PVOD 上完成，该数据集附完整元信息，且其目标列经检验为真实计量值（见 3.11 节）。

除精度之外，本文在分析过程中还发现了两件与数据本身有关、值得记录的事：一是原始时间戳为世界时而非北京时间，若不换算，太阳位置与日内曲线全都会错；二是在「同时刻气象加历史观测」这一最有利条件下，表现最好的竟是线性回归而非任何树模型。前者属于数据质量检查，后者需要给出机制解释，二者分别在 2.2 节与 3.4 节交代。

2 数据与方法

2.1 数据说明

本文使用公开数据集 PVOD (Photovoltaic Output Dataset)，含河北十座光伏电站的运行记录，共 271968 条、15 分钟粒度，时间跨度自 2018 年 6 月 30 日至 2019 年 6 月 13 日，并附有装机容量、经纬度、阵列倾角、组件型号等元信息 [8, 9]。

该数据集把气象变量分成两组：`nwp_*` 共 7 项，为数值天气预报给出的预报值，含总辐射、直接辐射、气温、相对湿度、风速、风向与气压；`lmd_*` 共 6 项，为站内辐射计与气象仪的实测值，含总辐射、散射辐射、气温、气压、风速与风向。预测目标为电站输出功率，单位 MW。

十座电站的装机容量相差数倍（6.6~35 MW），功率绝对值无法直接比较，故目标统一归一化为「功率/装机容量」，误差单位记作% 装机容量，跨站可比。

关于数据取舍需要说明两点。第一，任务指定的首选数据集为 Kaggle 上印度两座光伏电站约 34 天的记录，备选为 PVOD，本文选的是备选。理由有两层：一是 Kaggle 那份需要注册账号才能下载，而 PVOD 由 GitHub 直接可取；二是它只含两座电站、约一个月，做不了「轮流把每一站当作目标站、其余站参与训练」的留一站交叉验证——而研究问题二恰恰是围绕跨站迁移展开的，十座电站才有十次独立的验证机会。第二，在摸索阶段我还接触过宁夏某光伏电站 2019 年的公开数据 [5]，它在预备实验中显出两个难以处理的性质：目标列与总辐射的比值几乎恒定（变异系数仅 0.23%），近似由辐射按固定系数换算而来，而非独立计量的电表读数；同时未公开经纬度与装机容量，无法完成容量归一化，也就无法与其他电站横向比较。相比之下，PVOD 的目标列经检验为真实计量值（见 3.11 节）且附完整元信息，故本文全部实验在 PVOD 上完成。换数据这一步不是图省事，是被上面这些性质逼出来的。

2.2 数据质量检查

按行统计，271968 条原始记录中无任何缺失值；重复时间戳 1 条，已保留首次出现者。剔除「总辐射为 0 却仍有出力」的夜间异常记录 165 条 (0.061%) 后，共用 271803 条。归一化出力的峰值在十站之间落在 0.602 至 1.338 区间，其中 station04 达 1.338，即出力超出登记装机容量 33.8%，应是容量登记错误；station09 仅 0.602，出力长期偏低，疑似限发。这两站因此在后续解释结果时被单独指出。

除常规检查外，本文发现三处若不留神就会让实验失效的问题，逐条记录如下。

(1) **时间戳为世界时，不是北京时间**。按原始时钟小时统计总辐射，其峰值出现在 4 时，而河北约在 $115^{\circ}\text{E}\sim 119^{\circ}\text{E}$ ，正午应在 12 时前后。换算为北京时间 (+8 小时) 后，峰值回到 12 时，日落与日出时刻也与纬度相符。图 1 给出两支曲线的对比。若不换算，太阳位置、晴空指数、日内曲线与「白天」样本的判定全都会错位 8 小时。本文全流程统一按北京时间处理。




图 1: 总辐射日变化：按原始时间戳统计的峰值出现在 4 时，换算为北京时间后落在 12 时

(2) **时间序列存在天数级断点**。十站合计出现 130 处非 15 分钟的间隔，最大一处跳了 6 天。这类断点对时序建模是致命的：直接对功率做 `shift(1)` 时，断点后第一条记录取到的「上一刻」其实是数天前同一时刻的值，滞后特征完全失真。本文因此不使用普通的 `shift`，而是先核对相邻记录的时间间隔，间隔不等于 $k \times 15$ 分钟者一律置为缺失，再由 `dropna` 整行剔除。此外，测试集与训练集严格按时间先后切分、绝不打乱，以免相邻时段的天气模式跨越边界造成泄露。

(3) **存在「平顶」片段，疑似缺测被常数填充**。station01 的 2019-06-10 最具代表性：10:00 至 19:00 总辐射恒为 837.80 W/m^2 ，功率恒为 14.03 MW，曲线呈方波而非钟形。按「总辐射连续 8 个点 (2 小时) 以上完全相等且数值大于 100 W/m^2 」判定，十站合计 171 行属于此类 (占 0.063%)，集中在 4 个站日。占比很小，不足以影响整体结论，但足以在挑「典型日」画图时把人带偏，故本文在选取典型日时将其排除。

2.3 实验设定与评估指标

为对应三种真实的信息可得性，本文设置三个设定。三者的预测目标都是同一时刻的电站出力，差别只在输入可用什么。

设定甲（同时刻站内实测气象）。输入为预测时刻本身的站内实测读数，即 6 个 `lmd_*` 变量，叠加时刻正余弦编码 `hour_sin`、`hour_cos`、`doy_sin`、`doy_cos`，合计 10 个特征。该设定对应「站内气象站实时可得」的现报场景。

设定甲'（同时刻数值天气预报）。输入换成 7 个 `nwp_*` 变量加同样的 4 个时刻编码，合计 11 个特征。它对应没有站内气象站、只能接入预报的电站。把甲与甲'并列，能量化「预报误差」相比「站内实测」要让精度损失多少。

设定乙（仅历史观测）。剔除预测时刻自身的一切读数，只使用此前若干刻钟的观测：上一刻及 2、3、6、12 刻钟前的总辐射，上一刻钟的功率，以及 1、6 刻钟前的气温，再叠加同样的 4 个时刻编码，合计 12 个特征。该设定不存在数据泄露，对应「只能拿已采集数据估算当前出力」的场景，是三者中条件最苛刻的。

设定丙（同时刻气象 + 历史观测）。把甲与乙的输入合并：6 个 `lmd_*` 变量、上一刻功率、上一刻辐射，再加 4 个时刻编码，合计 12 个特征。加这一组是为了回答「在已知上一刻功率之后，同时刻气象还能不能再贡献一点」——甲没有自回归项，直接与乙比较并不公平。

四个设定采用同一套时间切分：按时间先后划分，前 70% 样本用于训练、后 30% 用于测试，训练与测试之间不打乱样本顺序。所有模型固定随机种子 `random_state=42`，保证可复现。

预测性能用平均绝对误差 MAE、均方根误差 RMSE 与决定系数 R^2 三项指标衡量，单位均为 % 装机容量。另设两条不做学习的朴素基线作对照：设定甲与甲' 采用由训练集最小二乘拟合的固定系数公式 $P = k \cdot \text{GHI}$ ，设定乙与设定丙采用 Persistence 基线，即直接把上一刻钟的功率当作本刻钟的预测值。

参与比较的模型为线性回归、随机森林、梯度提升树 GBDT、LightGBM 与 XGBoost 五种。为保证可比，四个树模型统一取 100 棵、学习率 0.1；随机森林取 200 棵（其原理见 [2]）。调参过程有两点记录在案：一是 XGBoost 的库默认学习率是 0.3，在若干站上明显过拟合，故另设一行「默认学习率」作为对照如实列出；二是树数并非越多越好，试过 300 棵后十站平均反而变差（LightGBM 由 2.2821 升至 2.4538），说明本任务 100 棵已足够。

2.4 跨站迁移实验的设定

2.3 节的四个设定都只用一座电站的数据训练。为回答「能否借用别站数据改善本站预测」，本文在 PVOD 十站上做留一站交叉验证（Leave-One-Station-Out）：轮流把每一站当作待预测的目标站，其余九站作为源数据，共跑十轮，使结论不受单个站的偶然性支配。每轮比较四种做法：

- A 从零训练：只用目标站自己的训练数据。
- B 预训练 + 微调：先在其余九站上训练，再用目标站数据继续加树。
- C 零样本迁移：直接把九站模型套到目标站，完全不看目标站的任何标签。
- D 多站联合训练：九站与目标站数据混合训练，目标站样本权重放大 5 倍。

这里有一处公平性必须控制：B 的总树数是「500 棵预训练 + 200 棵微调」，因此 A 也取 700 棵，否则 B 的胜利可能只是「树更多」的胜利，而非迁移本身有效。四种做法统一使用 LightGBM（后续 3.10 节会换 XGBoost 复跑一遍），目标站内部仍按时间前 70% 训练、后 30%

测试。输入特征为 6 个站内实测气象变量 lmd_* 加 6 个时刻/风向编码，与 3.2 节设定甲的口径一致（时间戳同样已换算为北京时间），因此本节结果可与单站实验横向比较。

树模型的「微调」只是接着加树，已经长出来的老树一棵都改不掉。神经网络没有这个限制，可以继续反向传播，所有权重都跟着变。这种差别会不会改变迁移的结论，值得单独验证。因此本文用同一批数据、同一套清洗与切分，把上述实验又用 LSTM 做了一遍，方案与树模型一一对应，另加一组对照：

- A 从零训练：只用目标站自己的训练数据，训练 15 轮。
- B 预训练 + 微调：九站上预训练 10 轮，再用目标站数据以较小学习率微调 5 轮。
- C 零样本迁移：预训练完成后直接在目标站测试，不看目标站任何标签。
- D 多站联合训练：九站与目标站数据混合训练，目标站样本权重放大 5 倍。
- E 预训练初始化 + 训满：用预训练权重作初始值，再按与 A 完全相同的 15 轮常规步长训练。

E 是为分辨「预训练没用」和「微调轮数没给够」而加的。它与 A 的唯一差别是初始权重：A 从随机初始化出发，E 从源站学到的权重出发；训练轮数、学习率、数据完全一样。

两处细节需要说明。B 与 E 共用同一份预训练权重（深度复制后各自继续训练），否则起点不同，比较就不干净。LSTM 的 D 额外输入四个站点静态属性（容量、倾角、经纬度），与树模型 D 的条件对齐；这四个量只有十个取值，统一按十站统计量标准化，若用单站内部统计量，标准差为零会把它整体缩成零，模型就分不出站了。网络为单层 LSTM 接一层线性输出，输入窗口取过去 12 个时刻（3 小时）的气象序列，训练设备为 Apple MPS，十站全部跑完约 20 分钟。

3 结果与分析

本节先做数据的可视化探索与相关性分析，再依次报告总体预测性能、单站深度模型对照、树模型与线性模型的能力差异、误差在不同天气下的分布、模型依赖哪些特征、特征消融结果、跨站迁移检验与 LSTM 对照，最后给出一项针对数据本身性质的检验。所有数字均由 `code/` 目录下的脚本自动生成并写入 `results/`，可复现。

3.1 数据的可视化探索与相关性分析

在建模之前先用绘图看清数据的形态，这一节对应基础要求中的「可视化与解读」，并回答四个具体问题：出力长什么样、出力由哪些因素决定、十个站的规律是否一致、以及这些相关关系里有多少是真的、多少是被混淆出来的。

第一组图看出力本身的形态。

图 2 给出晴、多云、阴三类典型日的曲线：晴天是光滑的钟形，日峰值出力达 99.6% 容量；多云日辐射被云层反复遮挡，出力随之剧烈起伏（峰值 80.5%）；阴天辐射长期低平，出力仅 20.4%。图 3 给出全年逐日峰值，可见冬季明显低于夏季，季节性强。图 4 是辐射与出力的散点，




图 2: station01 三类典型日的出力与辐射 (已排除平顶异常日)




图 3: station01 全年逐日峰值出力与 7 日滑动平均




图 4: 十站合并的辐射-出力散点图

相关系数 0.8568——注意散点并非一条细线而是有明显宽度，这恰恰说明出力并不由辐射唯一决定，这正是设定丙中恒等映射项（上一刻功率）能派上用场的空间。

需要补充一点：图 4 的十站合并相关系数是 0.8568，而后面逐站计算的相关平均有 0.9650，两者相差不小。差的这一部分并不是随机噪声，而是各站装机容量与转换效率不同带来的系统性差异——把不同规模的电站混在一起画散点，点自然就散开了。这正是本文坚持按装机容量归一化、并且分站建模与评估的原因。

第二组图看变量之间的相关结构。图 5 给出十个站各自的相关矩阵，六个变量的排列次序在十个站上完全一致，说明这套数据的物理规律是稳定的，不存在某座电站「性格特殊」到需要单独建模的程度。图 6 把「与出力的相关」单独抽出来，按十站均值排序并给出站间标准差，结果见表 1。

表 1: 各气象因子与归一化出力的皮尔逊相关系数（十站统计）

变量	十站均值	站间标准差	最小	最大
总辐射	0.9650	0.0260	0.9018	0.9908
散射辐射	0.8160	0.0937	0.6807	0.9519
风速	0.3951	0.0582	0.2976	0.5114
气温	0.3468	0.0559	0.2759	0.4395
气压	-0.1189	0.0741	-0.2509	-0.0191

总辐射以 0.9650 的相关度居首，且站间标准差只有 0.0260，说明它是十站通用的、最可靠的预测依据；散射辐射次之（0.8160），但站间波动明显变大。风速与气温的相关都只有 0.4 上

图11 十站各自的皮尔逊相关系数矩阵（对角线与自身相关恒为1，已省略）




图 5: 十座电站各自的皮尔逊相关系数矩阵（对角线与自身相关恒为 1，已略去数值）




图 6: 各气象因子与归一化出力的相关强度，误差棒为十站之间的标准差

下；气压甚至接近 0。




图 7: 控制总辐射后各因子与出力的偏相关（十站均值，误差棒为站间标准差）

这里有一个必须澄清的疑点。按光伏物理常识，组件温度升高会使开路电压下降、效率降低，因此气温与出力之间应当呈**负**相关；但表 1 显示它是 +0.3468，符号相反。这是不是说明数据有问题？并不是。原因是气温与总辐射高度共线——夏天既热又晒，于是「热」和「发电多」在统计上被绑在了一起，形成典型的混淆相关。

为验证这一点，本文计算了控制总辐射之后的一阶偏相关

$$r(xy | z) = \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{(1 - r_{xz}^2)(1 - r_{yz}^2)}},$$

结果见图 7：气温与出力的相关从 +0.3468 掉到 +0.0504，几乎归零，且站间标准差高达 0.2231——也就是说残余关联在十个站上连符号都不一致。风速也从 +0.3951 降到 +0.0940。


这个结果有两层含义。其一，气温对光伏效率的影响是真实存在的物理效应，但在本数据中被与辐射的共线关系掩盖了，模型分不开二者，这正好解释了 3.7 节消融实验里「删掉温度特征模型几乎不变」的现象，也提醒我们不能把该结果误读成「温度对光伏没有影响」。其二，相关矩阵只能说明变量长得像不像，不能说明谁重要；真正的贡献要由后面特征重要性与消融实验来回答。

第三组图检验预报值是否靠得住，因为它直接决定设定甲'能做到多好。图 8 给出同名变量的预报值与实测值的相关与归一化误差，十站平均见表 2。

表 2: 预报值与实测值的一致程度（十站平均，nRMSE 为误差除以实测量的标准差）

变量	相关系数	nRMSE
总辐射	0.9010	0.4455
气温	0.9773	0.2195
气压	0.9917	0.3038
风速	0.4682	3.0611

图13 数值天气预报 nwp_* 与站内实测 lmd_* 的一致程度

图 8: 数值预报 nwp_* 与站内实测 lmd_* 的一致程度 (十座电站)

气温与气压的预报相当准 (相关 0.98 以上)，但**总辐射的预报误差达到实测波动幅度的 44.55%**，风速预报更是几乎不可用 (相关仅 0.4682)。总辐射恰恰是预测出力最关键的那一个变量，它的预报误差会原样传导到功率预测上，这解释了为什么设定甲' 的误差 (4.8725) 几乎是设定甲 (2.4738) 的两倍。

3.2 总体预测性能

表 3 给出四个设定下的全部结果。逐层看下来，有三点值得说。

第一，信息越全，误差越小，且增益主要来自「同时刻气象」而非「更多模型」。设定乙只有历史观测，最好的 LightGBM 为 2.2821；加入同时刻实测气象 (设定丙) 后降到 1.4942，误差减少约三分之一。把同时刻实测气象换成数值天气预报 (设定甲')，最好的随机森林为 4.8725，几乎是设定甲 (2.4738) 的两倍——预报误差本身就值这么多。这个对照说明：对这类超短期预测，接入一条实时气象实测，比换一个更复杂的模型更划算。

第二，在条件最苛刻的设定乙里，机器学习确实管用，但增益有限且不稳。LightGBM 把 MAE 从 Persistence 的 2.5808 降到 2.2821，降幅 11.57%；随机森林降 5.60%；而 XGBoost 反而比基线差 2.88%。差距之所以不大，原因在特征重要性里——设定乙中「上一刻功率」一项就占了 96% 的重要性 (见 3.6 节)，模型能做的只是对这条强特征做小幅修正。

第三，也是本文最意外的一点：在设定丙中，表现最好的是线性回归，而不是任何树模型。它比第二名的 LightGBM 低 8.8%，比 Persistence 低 41.74%，且 R^2 达 0.9849，是全场唯一超过 0.98 的。这个结果反直觉，需要专门解释，见下一小节。

3.3 单站深度模型对照：复杂模型是否一定更好

前面几节的比较都停留在「朴素基线 vs 树模型 vs 线性回归」这一层。本节把 LSTM 也放进同一条件，回答研究问题一：模型越复杂，预测一定越准吗？

实验条件与 3.2 节完全一致：同一份数据、同一条前 70%/后 30% 的时间切分、同一套信息可得性约束。LSTM 取两层、隐藏单元 64、回看窗口 12 步 (3 小时)、Adam 学习率 10^{-3} 、固

表 3: 四个设定下的十站平均预测误差 (MAE 与 RMSE 单位为% 装机容量)

设定	方法	MAE	RMSE	相对基线改善
甲' 预报气象	随机森林	4.8725	9.6291	13.88%
	LightGBM	4.9060	9.2251	13.28%
	XGBoost	5.2421	9.7543	7.34%
	GBDT	5.3871	9.6372	4.78%
	朴素基线: 固定系数	5.6575	10.6433	—
	线性回归	6.3862	10.1306	-12.88%
甲实测气象	LightGBM	2.4738	5.3336	18.58%
	随机森林	2.5202	5.6232	17.05%
	XGBoost	2.7123	5.7719	10.73%
	朴素基线: 固定系数	3.0383	6.2068	—
	GBDT	3.0652	5.9454	-0.89%
	线性回归	3.6613	6.2300	-20.50%
乙纯历史	LightGBM	2.2821	5.2633	11.57%
	随机森林	2.4364	5.5432	5.60%
	朴素基线: Persistence	2.5808	5.6427	—
	线性回归	2.5324	5.2839	1.88%
	GBDT	2.5467	5.5861	1.32%
	XGBoost	2.6552	5.8380	-2.88%
丙实测气象 + 历史	线性回归	1.4942	3.1507	41.74%
	LightGBM	1.6376	3.8300	36.15%
	随机森林	1.6689	4.0761	34.93%
	XGBoost	1.7520	4.0221	31.69%
	GBDT	1.8384	4.0114	28.32%
	朴素基线: Persistence	2.5648	5.6214	—

定训练 30 轮，未做早停与超参搜索；树模型统一 100 棵树、学习率 0.1。两者唯一的差别是输入的组织方式：树模型看到的是若干个人工构造的滞后特征（*GHI* 滞后 1/2/3/6/12 步、上一时刻功率等），LSTM 看到的是过去 3 小时逐点的多变量序列，二者覆盖的时间跨度相当，信息量可比，因此这个对照是公平的。需要说明的是，跨时间的断点窗口已被剔除，避免把几天前的同一时刻当成连续历史。

表 4: 单站内六类方法的十站平均 MAE (% 装机容量) 与单站平均训练耗时 (秒)

设定	方法	MAE	训练耗时 (s)
甲实测气象	LightGBM	2.4738	0.47
	随机森林	2.5202	1.76
	XGBoost	2.7123	0.17
	朴素基线：固定系数	3.0383	—
	LSTM	3.1467	9.63
	线性回归	3.6613	0.00
甲' 预报气象	随机森林	4.8725	2.60
	LightGBM	4.9060	0.48
	XGBoost	5.2421	0.20
	朴素基线：固定系数	5.6575	—
	LSTM	5.9380	9.63
	线性回归	6.3862	0.00
乙纯历史	LightGBM	2.2821	0.49
	随机森林	2.4364	2.59
	线性回归	2.5324	0.00
	朴素基线：Persistence	2.5808	—
	XGBoost	2.6552	0.19
	LSTM	4.1694	9.63
丙气象 + 历史	线性回归	1.4942	0.00
	LightGBM	1.6376	0.42
	随机森林	1.6689	2.36
	XGBoost	1.7520	0.17
	朴素基线：Persistence	2.5648	—
	LSTM	3.1624	9.63

结果相当干脆：LSTM 在四个设定上**全部落后**，见表 4 与图 9。最好情况下（设定甲'）它比最优树模型差 21.9%，最差情况下（设定丙）差 111.6%；在设定乙里它甚至输给了完全不需要训练的 Persistence 基线 61.6%。也就是说，本任务上「更复杂的模型」带来的不是精度提升，而是明确的负收益。

为什么会这样？本文给出三点解释。

第一，这个任务几乎不需要「记忆」。光伏出力与同时刻辐射之间是近似瞬时的物理映射，决定当前出力的是「现在晒不晒」，而不是「三小时前晒不晒」。LSTM 的核心能力是捕捉长程时间依赖，而这项能力在本任务上恰好用不上——真正需要的信息（当前辐射、上一时刻功率）在




图 9: 单站内六类方法在四个设定下的十站平均误差

输入里已经直接给出了，让模型再去从序列里「回忆」一遍，反而增加了拟合难度。

第二，数据量与模型容量不匹配。每站约 1~3.3 万条记录，对需要大量样本才能估稳参数的神经网络来说偏少；树模型在小样本上天然更稳健。

第三，序列里混进了大量夜间段。十个站的夜间样本平均占 49.07%，这些时段出力恒为 0，与白天的物理规律完全不同。LSTM 必须用同一套权重同时学会「夜间恒零」和「白天跟随辐射」两种模式；而树模型只要看一眼辐射值就能把两者彻底分开。这是结构上的劣势，不是调参能弥补的。

还有一点值得单独指出：训练代价相差悬殊。表 4 最后一列显示，线性回归只需 0.003 秒、LightGBM 约 0.47 秒，而 LSTM 需要约 9.6 秒，是线性回归的三千余倍，精度却更差；若把调参成本也计入，差距只会更大。这对工程选型是一个很实际的提醒：在这类表格型回归任务上，先把基线模型和树模型做到位，往往比直接上深度模型划算得多。

需要说明的是，这并不意味着深度模型在光伏预测中没有价值——它只是说明在「单站、中等数据量、以同时刻物理量为主」这一特定条件下不够划算。下一节会看到，当任务换成跨站迁移时，LSTM 的表现规律与树模型并不相同。

3.4 树模型为什么学不好「上一刻功率」

上一小节留下的问题是：为什么线性回归能在设定丙中胜出。本文的假说是，Persistence 本质上是一个硬编码的恒等映射 $P(t) = 1.0 \times P(t-1)$ ；线性回归能学到接近 1 的系数从而复现它，而树模型只能输出叶节点内训练样本的均值，天生做不到「输出等于输入」，于是把高值压低、低值抬高。

为验证这个假说，本文做了一个极简对照：每站只用「上一刻功率」一个特征，分别用硬编码的 Persistence、线性回归与随机森林预测，结果见表 5。

结果支持该假说。随机森林单独用这一个特征时，比直接把该特征当预测值差了 22.90%；线性回归学到的系数在十站上都接近 1 (0.9744~0.9874)，比随机森林好，但仍略逊于硬编码的 1.0，因为最小二乘为压低整体误差而把系数往均值方向拉了一点。

表 5: 恒等映射检验：每站只用「上一刻功率」一个特征（十站平均，MAE 单位% 装机容量）

预测方式	十站平均 MAE	相对 Persistence	说明
Persistence（硬编码系数 1.0）	2.5648	—	直接令 $P(t) = P(t - 1)$
线性回归（学到系数 k ）	2.7136	-5.80%	系数 k 落在 0.9744 ~ 0.9874，平均 0.9788
随机森林（200 棵，分段常数）	3.1521	-22.90%	无法表达恒等映射

这一机制同时解释了另外两个现象。其一，设定丙中线性回归胜出：它既能写出 $P \approx 0.98 \times P(t - 1)$ 的恒等映射，又能用气象项做线性修正，而树模型在分段平均时会破坏恒等关系。其二，3.5 节将展示，在辐射平稳的时段随机森林反而大幅输给 Persistence——正因为那些时刻几乎就是恒等映射。

需要说明的是，这不代表「越简单的模型越好」。在设定甲'（预报气象）中，线性回归是全表最差的（-12.88%），说明当输入与目标的关系明显非线性时，线性模型就会失效。真正稳妥的说法是：在含强自回归项的设定里，线性基线与树模型应当并列比较，不能想当然地只上树模型。

3.5 误差的天气分布（拓展一）




图 10: 不同天气场景下随机森林相对 Persistence 基线的误差

把十站测试集合并，按晴度（晴空指数 kt ）、辐射突变强度（ $|\Delta GHI|$ ）、光照强度（ GHI ）三个维度分组，结果见图 10。为排除干扰，此处只统计有效发电时段（实测总辐射大于 50 W/m^2 ），并在计算晴空指数前先限定太阳高度角——否则日出日落附近大气路径极长、 kt 天然偏低，会把「阴天」这一档撑得特别大，那不是云造成的。

中栏（辐射突变强度）的结论最清晰：模型增益几乎全部集中在辐射有变化的时候。突变 $30 \sim 60 \text{ W/m}^2$ 一组（10853 个样本）降幅 14.54%，剧变超过 60 W/m^2 一组（10827 个样本）降幅 17.90%；而辐射平稳（ $< 10 \text{ W/m}^2$ ，3276 个样本）时，随机森林 MAE 为 4.2285，反而比 Persistence 的 1.6077 差了 163%。这正是上一小节所说的恒等映射问题：辐射平稳意味着功率也平稳，此时 Persistence 已接近最优，模型再去拟合只会引入额外波动。

左栏（晴度）表现为：多云（ $0.35 \leq kt < 0.6$ ，8192 样本）降幅最大，达 27.50%；阴天

($kt < 0.35$, 8794 样本) 降幅 7.74%; 晴天 ($kt \geq 0.6$, 15185 样本) 反而为 -13.42% 。晴天的负值同样符合上述逻辑——万里无云时辐射曲线光滑, Persistence 本身就非常准。

右栏 (光照强度) 中, 中光 ($200 \sim 600 \text{ W/m}^2$, 11575 样本) 降幅 23.03% 、弱光 19.27% , 而强光 (≥ 600 , 12914 样本) 为 -24.72% 。强光时段多为晴空, 与左栏晴天一致。

综合三栏可以给出一条工程上可用的判据: **Persistence 在平稳晴好天气下是天然强基线, 不应被直接忽略; 模型的价值集中在云层扰动导致辐射起伏的时段。**实际部署时宜按辐射突变强度切换预测策略, 而不是全天只跑一个模型。

3.6 特征重要性 (拓展二)




图 11: 气象因子与出力的相关系数 (十站平均)

图 11 先给出相关分析的全局印象: 站内实测总辐射与出力的相关系数最高, 预报总辐射与预报直接辐射次之, 气温、气压、风速、风向等与出力的相关性则明显偏低, 且实测与预报两组变量之间自身高度相关。这预示了后面消融实验的结果——辐射类之外的气象因子能提供的信息有限。

图 12 给出三个设定的特征重要性排序, 取十站平均 (单站排序有偶然性, 十站平均才稳), 误差棒表示站间标准差。

设定乙中, 上一刻功率 P_{lag1} 的重要性高达 0.961, 站间标准差仅 0.007, 其余十一个特征合计不足 0.04。这直观说明为什么设定乙的提升有限——信息几乎全在一条特征里。滞后辐射 GHI_{lag2} 至 lag12 的重要性虽小却稳定非零, 它们的作用是当辐射突变、上一刻功率失效时提




图 12: 三个设定下随机森林特征重要性的十站平均排序（误差棒为站间标准差）

供补充。

设定丙中格局变成 GHI 0.634 与 P_lag1 0.324 两强并立，两者合计约 96%，散射辐射贡献 0.030，其余特征均在 0.003 以下。这个结构正好对应 3.2 节：既要有「同时刻辐射」定位当前天气，也要有「上一刻功率」提供恒等映射的锚点。

设定甲（实测气象）中总辐射 0.824、散射辐射 0.139 合计 96.3%，气象因子只有辐射类起作用。设定甲'（预报气象）则不同：预报总辐射 0.384 与预报直接辐射 0.360 相加也只有 0.744，时刻余弦编码占到 0.119，气压、湿度、风向等也各有贡献（合计约 0.106）。原因是预报辐射本身带有误差，模型无法仅靠它定出出力，只好借助时刻与季节信息来补偿——这也从侧面印证了 3.2 节「预报误差直接转化为精度损失」的结论。

3.7 特征消融（拓展二补充）

表 6: 特征消融：整组删掉某类特征后的十站平均 MAE（随机森林，单位% 装机容量；「相对完整」按十站平均 MAE 计算）

设定	特征集	特征数	MAE	相对完整
丙实测气象 + 历史	完整	12	1.6689	—
	删全部同时刻气象	6	2.6952	+61.49%
	只留上一刻功率	5	2.7131	+62.56%
乙纯历史	完整	12	2.4364	—
	删气温滞后	10	2.4237	−0.52%
	删时刻编码	8	2.4385	+0.09%
	只留上一刻功率	5	2.7131	+11.36%
甲实测气象	完整	10	2.5202	—
	删气温	9	2.5250	+0.19%
	删气温 + 气压 + 风速	7	2.4837	−1.45%

表 6 给出消融结果，图 13 为对应柱状图。四组结论如下。




图 13: 特征消融结果 (绿色为完整方案, 红色为删减后)

(1) **同时刻气象的贡献是决定性的。**设定丙中, 把 6 个同时刻气象变量整组删掉, MAE 由 1.6689 恶化到 2.6952, 增加 61.49%; 删到只剩上一刻功率时恶化 62.56%。这说明即便已经有了自回归项, 同时刻气象仍携带大量独立信息, 两者不可互相替代。

(2) **次要气象因子 (气温、气压、风速) 几乎没有独立贡献。**设定甲中删掉气温, MAE 只变化 0.19%; 连气温、气压、风速一起删 (10 个特征减到 7 个), MAE 反而略降 1.45%。这提示在辐射类特征已在场的情况下, 这些气象量提供的信息已被吸收。

(3) **时间特征工程 (时刻正余弦编码) 的收益很小。**设定乙中删掉 4 个时刻编码, MAE 仅从 2.4364 变为 2.4385, 恶化 0.09%。这与预期不同——一般认为时刻编码能帮助模型识别日内规律。可能的原因是: 滞后辐射与滞后功率本身已经隐含了时刻信息 (日出前后辐射自然低), 时刻编码提供的增量因此有限。本文如实记录这一结果, 不因为它「看起来应该有用」就把它写成有效。

(4) **气温滞后删掉后误差不升反降 (-0.52%)。**这与第 (2) 条一致, 同样说明温度相关特征在本数据上不带来可测增益。

需要强调一点: 以上消融结果只能说明「在本数据、本特征组合下, 这些变量不带来可测增益」, 不能推广成「温度对光伏出力没有物理影响」。光伏组件的温度效应确实存在 (约 $-0.3 \sim -0.4 \text{ } \%/^{\circ}\text{C}$), 只是它在本数据里与辐射高度共线, 被辐射效应吸收, 模型无法把两者分开。

3.8 跨站迁移检验 (拓展三)

前文所有结论都来自同一条流水线, 换一座电站是否仍然成立, 尚未检验。本节回答这个问题。

表 7 给出十站平均结果, 排序为 $D > B > A > C$ 。多站联合训练平均把误差压低 14.61%, 八个站改善; 预训练后微调则几乎没有作用, 平均仅 -0.36% , 只有六个站改善。两者的差别在于: 微调是在别人已经成型的 500 棵树上再追加 200 棵, 老树始终参与预测、改不掉, 目标站的数据只能影响新加的那部分树; 联合训练从一开始就把目标站数据混进去, 样本权重又把目标站样本放大 5 倍以抵消数量劣势, 模型没有先入为主的包袱, 因此更直接有效。

需要说明本节的输入口径。这里用的是站内实测气象 lmd_* , 与 3.2 节的设定甲一致, 以便两组结果可以横向比较。在预备阶段本文也曾用预报气象 nwp_* 跑过同一套实验, 当时得到的提升幅度明显更大 (B 17.83%、D 24.77%), 但那份结果既未做时区修正、口径也与主线不符,

表 7: 留一站交叉验证的四方案对比 (全天口径, MAE 与 RMSE 单位为% 装机容量); 表内「相对 A 的改善」为逐站算出后再取平均, 与 MAE 列的十站平均口径略有差异。

方案	MAE	RMSE	相对 A 的改善	优于 A 的站数
A 从零训练	2.744	5.731	—	—
B 预训练 + 微调	2.584	5.455	−0.36%	6/10
C 零样本迁移	4.657	8.614	−68.11%	3/10
D 多站联合训练	2.315	5.030	+14.61%	8/10




图 14: 留一站交叉验证结果: (a) 各站 MAE 对比; (b) 相对从零训练的改善幅度

已作废。两套结果的差别本身很有信息量：当本站已有高信息量的实测气象时，单站模型已经足够强，跨站迁移能带来的边际收益就小；反过来，如果输入只能依赖误差较大的预报值，迁移的价值就会凸显。也就是说，迁移值不值得做，取决于本站信息条件的贫富。

夜间出力恒为 0，容易预测，会把全天口径的 MAE 拉低。本文因此同时统计只含辐射大于 0 的白天口径：A 为 4.532、B 为 4.343 (−1.15%)、C 为 8.045 (−71.32%)、D 为 3.886 (+13.29%)，排序与全天口径完全一致。两套口径给出同一排序，说明上述结论不是口径选得好才好看。

零样本迁移的表现最不稳定，只在 3 个站上优于从零训练，平均反而差 68.11%。它在 station03 (1.572 对 2.238) 与 station08 (1.686 对 2.091) 上确实更好，而在 station09 上从 2.703 恶化到 10.116 (3.7 倍)、station01 上从 2.581 恶化到 7.497。差别来自「目标站有多典型」——station09 疑似长期限发、station04 存在容量登记错误，这两站的出力特性无法被通用模型覆盖；而 station03、station08 贴近典型站，通用模型反而比本站小数据训出来的更稳。所以零样本不是不能用，但用之前必须先判断目标站是否被源站覆盖。

本文还检验过「基线越弱、迁移收益越大」这一常见说法：按从零训练的 MAE 把十站分成两半，树模型上较弱的一半平均提升 15.51%、较强的一半 13.70%，差距很小且不显著 (Pearson $r = 0.138$, $p = 0.704$)。因此本文不宣称迁移收益与基线强弱之间存在稳定关系。能确定的只有一条：只要目标站与源站同属一类电站、出力规律相近，多站联合训练就能带来提升。

3.9 同任务上的 LSTM 对照 (拓展四)

把上面这套实验换成 LSTM 重做，可以检验一个更一般的问题：换一个「能继续学习」的模型，跨站迁移的规律会不会改变。

表 8: LSTM 五方案在留一站交叉验证下的平均表现 (全天口径, MAE 与 RMSE 单位为% 装机容量); 表内「相对 A 的改善」为逐站算出后再取平均, 与 MAE 列的十站平均口径略有差异。

方案	MAE	RMSE	相对 A 的改善	优于 A 的站数
A 从零训练	3.941	6.999	—	—
B 预训练 + 微调	3.169	5.738	+18.01%	7/10
C 零样本迁移	6.548	10.891	-61.45%	3/10
D 多站联合训练	2.374	5.034	+36.15%	10/10
E 预训练初始化 + 训满	2.681	5.263	+28.96%	9/10




图 15: LSTM 迁移实验结果: (a) 五方案平均误差; (b) 逐站改善幅度, 纵轴为对称对数刻度; (c) B 与 E 的逐站对比; (d) 微调收益与 LightGBM 的对照

表 8 的排序是 $D > E > B > A > C$, 树模型为 $D > B > A > C$ 。两个模型在最重要的一点上完全一致: **多站联合训练都是收益最大的做法** (LSTM 36.15%、树模型 14.61%), 也都远优于「预训练 + 微调」。图 14 与图 15 并列可以看出这一点。

差别出现在 B 上。树模型的「预训练 + 微调」几乎无效 (-0.36%), LSTM 上却把误差降低 18.01%、七个站有效。原因在于两种模型「怎么改」不一样: LSTM 微调时梯度会流回全部权重, 预训练学到的时序结构可以被目标站的数据按需重写, 于是「先预训练再微调」这套做法

能真正兑现；树模型的微调只能在老树上继续加，改不动既有结构，因此同样思路在树模型上失灵。

但不能据此说 LSTM 更强。LSTM 从零训练的基线本身就差得多 (3.941 对 2.744)，表 8 里每个方案的绝对误差也都高于表 7 中对应的树模型；它看起来「提升幅度大」，很大程度上是起点低、可提升空间大。准确的表述是：在同一组方案里，可微模型能靠微调拿到收益，树模型拿不到；而两者共同的、收益也最大的做法，都是直接做多站联合训练。

第二处发现与直觉相反：E 比 D 低 7.2 个百分点 (28.96% 对 36.15%)，且 E 的站间波动大于 D。说明预训练给出的起点只有在少轮数、小步长下才保得住；一旦按常规步长训满，源站学到的通用结构会被较快覆盖，也就是灾难性遗忘。这一点在单站试跑时曾给出相反的信号（当时 E 优于其余方案），把十站跑完才翻转。单站结论不足为凭，这也是本文坚持用留一站交叉验证的原因之一。

零样本迁移在 LSTM 上更不可用：平均变差 61.45%，只有 3 个站有效，station04 上 MAE 从 6.348 恶化到 24.776。两个模型都指向同一个结论——不校准地直接搬用别站模型风险很大，区别只是神经网络对输入分布的偏移更敏感。




图 16: 两种 learner 上跨站策略的收益对比（相对「从零训练」的误差降幅，十站平均；零样本迁移为负收益）

图 16 把两类模型的结果并列在一起：柱子在 D 处同时最高，说明「多站联合训练」是两种 learner 共同的最优解；而在 B 处两根柱子一高一低，正是「树模型加不了树、神经网络能改写权重」这一差别的直观体现。

3.10 XGBoost 上的迁移复现（拓展四补充）

上面两节的迁移实验有一个容易被人挑刺的地方：树模型只用了 LightGBM 一种。2.4 节交代过，四种做法统一以 LightGBM 实现；而 3.2 节的主实验里，树模型是 LightGBM 与 XGBoost 一起跑过的。若「多站联合训练最优」这条结论只有一类树模型撑着，说到底还是欠一次复现。

本文用一个单独的脚本（code/24_xgb_transfer_loso.py）补上这一步：把 learner 换成

XGBoost，数据与切分口径一字不改地重跑十站的 A/B/C/D 四个方案。超参按等价口径对齐——`num_leaves=31` 取 `max_depth=5`（31 叶的满二叉树深度就是 5），`min_data_in_leaf=20` 取 `min_child_weight=20`，bagging 与特征子采样都仍是 0.85，A 仍为 700 棵、B 仍是 500 棵预训练加 200 棵微调，以免出现「树多所以赢」的比较不公。

表 9 给出十站平均结果。排序是 $D > A > B > C$ ：多站联合训练把误差压低 4.11%（6/10 站），从零训练 2.619 次之，而预训练加微调反而把误差抬高 11.81%（只有 5 个站有效），零样本迁移平均恶化 91.32%，是四个方案里最差的，只有 2 个站不比从零差。零样本之所以崩得这么厉害，主要被两个站拖住：station04 从 5.909 涨到 10.391，station09 从 2.689 涨到 10.265——本站特征分布一旦与源站的 9 站整体差得远，别站训出来的树在原封不动搬过来时误差会成倍放大。

与 LightGBM 逐方案对照（图 17），三个策略上两种树模型的方向完全一致：D 都是正收益、C 都是大幅负值、B 都不成立。量级上 XGBoost 明显弱于 LightGBM——D 只降 4.11%（对 14.61%），C 恶化 91.32%（对 68.11%），B 的 -11.81% 也比 -0.36% 更差。这种差别来自两个库的实现细节而非机制本身，两者都是梯度提升树、都是增量建树，因此不宜把「提升几个百分点」当作树模型的固有性质，也不必为它做额外解释。但六次比较（三个策略 × 两种树模型）的符号全同，足以说明 3.8 与 3.9 两节得到的结论不是 LightGBM 一家偶然：

1. **多站联合训练始终排第一**——三种 learner 上都是它，所以在三类模型上都可以放心地把它当作默认做法；
2. **零样本迁移始终最差**——三种 learner 上都大幅为负，「直接搬别站模型」在任何一类模型上都行不通；
3. **「预训练 + 微调」只在可微模型上成立**——LSTM 上 +18.01%，两类树模型上分别为 -0.36% 与 -11.81%，把这条判据和「模型能不能反向传播」绑在一起看，比记具体数字更可靠。

需要如实交代的是：XGBoost 上联合训练的收益比 LightGBM 小得多（10 个站里只有 6 个改善，station09 上甚至从 2.689 变成 3.001 略有变差）。这说明多站联合的**有效性稳，收益大小**会随实现与超参浮动。工程上更稳妥的表述是「联合训练方向可靠、量级要按自己的数据和求解器实测」，而不是照抄某个百分比。

表 9: XGBoost 上留一站交叉验证的十站平均结果；表内「相对 A 的改善」为逐站算出后再取平均，与 MAE 列的十站平均口径略有差异。

方案	MAE	RMSE	相对 A 的改善	优于 A 的站数
A 从零训练	2.619	5.453	—	—
B 预训练 + 微调	2.671	5.560	-11.81%	5/10
C 零样本迁移	4.962	8.980	-91.32%	2/10
D 多站联合训练	2.416	5.100	+4.11%	6/10




图 17: 三种 learner 上跨站策略的收益对比（相对「从零训练」的误差降幅，十站平均；零样本迁移为负收益）

3.11 关于目标列性质的检验

在数据取舍阶段，本文对 PVOD 的目标列做过一项性质检验，以确认它是真实计量值而非换算量。做法是把每条记录的出力与同一时刻实测总辐射作比值，只取总辐射大于 50 W/m² 的白天样本，考察该比值是否恒定，以及控制辐射之后它是否还与气温有关。结果见表 10。

表 10: PVOD 目标列性质检验（十站，白天样本）			
检验量	十站范围	十站平均	对照：宁夏数据集
出力/辐射比值的变异系数 CV	19.40% ~ 58.97%	29.69%	0.23%
出力与辐射的相关系数	0.8889 ~ 0.9785	—	1.0000
比值与气温的偏相关（控制辐射后）	-0.5202 ~ 0.5726	0.0730	0.0038

两点结论。其一，PVOD 的出力与辐射相关虽高 (0.8889~0.9785)，但明显不是完美的线性关系：比值自身的变异系数在十站落在 19.40%~58.97%，平均 29.69%，与宁夏数据集的 0.23% 相差约 130 倍。这说明 PVOD 的出力保留了真实运行中的各种波动——云层遮挡、限发、组件污渍、逆变器效率变化等，是独立计量的电表读数。

其二，控制辐射后，比值与气温的偏相关在十站之间符号并不一致（-0.5202 到 +0.5726，平均 0.0730），对应的温度效应为 -1.29 ~ +1.66 %/°C，平均 +0.20 %/°C。理论上组件温度升高会降低效率，该效应应为负；十站平均却是正的，且站间符号混乱。本文的解释是：温度效应确实存在，但它在本数据中被限发（station09）、容量登记错误（station04）等未观测因素以及辐射的共线关系掩盖，单凭这份数据无法把它干净地分离出来。这也与 3.7 节消融实验「温度特征不带来可测增益」的结果互相印证。

综合来看，PVOD 的目标列可作真实出力使用，本文所有结论均基于此。而宁夏那份数据因其目标列近似为辐射的固定倍数换算值（CV 仅 0.23%）、且缺经纬度与装机容量，无法完成

容量归一化与跨站比较，故本文全部实验改用 PVOD。

3.12 误差的分方向统计与工程代价折算

前面用到的 MAE、RMSE 都是对称指标：把正误差和负误差取绝对值之后一起平均，只知道「差多少」，不知道「差在哪一边」。可第 4 节说的工程代价恰恰是有方向的。本节把预测误差按方向拆成两半——定义 $e(t) = \hat{P}(t) - P(t)$ ， $e < 0$ 记为**少报**（预测偏低，实际发多了）， $e > 0$ 记为**多报**（预测偏高，实际发少了），分别统计两侧的电量，再乘上真实电价折算成钱。

价格锚点全部取自公开文件，不用估算。弃光电量按河北南网 2025 年光伏结算均价 0.3433 元/kWh 计（冀南全年光伏结算电量 83.96 亿 kWh 的加权均价）；缺额电量按河北南网燃煤发电基准价 0.3644 元/kWh 计，这也是存量新能源机制电价的执行基准 [10]；做敏感性检验时取河北南网现货市场出清上限 1.2 元/kWh（2025 年 3 月 1 日起连续结算试运行）[11]。这里先按全额兑现的上界计算，即假定每个断面的方向性偏差都真实转化成了弃电或缺额，实际调度有吸收能力，真实代价只会更低。

表 11 给出十站在测试期（约 85 天、4.9 万个有日照的断面）的合计。

表 11: 误差两个方向的电量与代价（十站测试期合计，全额兑现上界）

预测方案	少报电量 (万 kWh)	少报代价 (万元)	多报电量 (万 kWh)	多报代价 (万元)
甲' 预报气象 + Persistence	630.55	216.47	1540.12	561.22
甲' 预报气象 + 线性回归	675.76	231.99	1412.63	514.76
丙实测气象 + LightGBM	432.20	148.37	203.67	74.22
丙实测气象 + 线性回归	308.54	105.92	223.83	81.56
丙实测气象 + Persistence	486.69	167.08	486.07	177.12

图 18 是同一组数据的柱状对照。




图 18: 少报代价（弃光）与多报代价（备用缺额）并不相等：设定甲' 以多报为主、设定丙以少报为主，风险方向整个翻了过来。

结论先说清楚，把信息源从「数值预报」换成「站内实测」以后，风险的主要方向被整个翻了过来。设定甲'上多报代价是少报的 2.6 倍 (561.22 万元对 216.47 万元)，钱主要花在「预测偏高、实际发不出来」这一侧；到了设定丙，LightGBM 反过来以少报为主，少报代价 148.37 万元是多报 74.22 万元的 2.0 倍；而 Persistence 基线两侧几乎相等 (167.08 对 177.12)，说明它压根不偏，只是都差。这个翻转在 MAE 上看不见——两个设定的 MAE 相差约 3 倍 (4.87% 对 1.64%)，但即便只看总量，也看不出风险是往哪边倒的。

少报也不是均匀撒在各处的。表 12 把设定丙下 LightGBM 的误差按同时刻总辐射分档，图 19 是同一组数据的柱状图。

表 12: 设定丙 LightGBM 的误差按同时刻总辐射分档 (十站测试期合计)

总辐射 GHI (W/m^2)	断面数	少报电量 (万 kWh)	多报电量 (万 kWh)
0 ~ 50	11014	59.32	5.80
50 ~ 300	13200	61.73	45.39
300 ~ 600	9725	80.43	66.98
600 ~ 1000	12800	163.76	72.16
> 1000	2294	66.95	13.33




图 19: 少报 (预测偏低) 随辐射增强而增大，强辐照时段是弃光的主要风险源。

两点值得注意。其一， $600 \sim 1000 \text{ W}/\text{m}^2$ 这一档单独贡献了 38% 的少报电量，而它正是全天出力最大、最容易装不下的时段——也就是说，真正的弃光风险不是出现在阴天，而是出现在晴天正午预测偏保守。其二， $0 \sim 50 \text{ W}/\text{m}^2$ 档的少报/多报比高达 10.2:1，是最偏的一档，但该档绝对量只有 $600 \sim 1000$ 档的三分之一，量级上不足以主导总代价。

既然少报更贵，直觉上「把预测整体抬高一点点」应该能省钱：多报只是略贵 (0.3644 对 0.3433，仅差 6%)，少报一点基本不亏，少掉的少报却是净赚。本文真的在 $\delta \in [-3\%, +3\%]$ 上逐点重算总代价扫了一遍，结果见表 13。

这是一条负面结果，但比正面结果更有用：这条路基本走不通。主口径下最优偏置只有

表 13: 整体偏置 δ 的扫描 ($\delta > 0$ 表示把预测整体抬高)

预测方案	主口径最优 δ	主口径节省	现货上限口径节省
丙实测气象 + Persistence	+0.0%	0.00%	0.63%
丙实测气象 + 线性回归	+1.3%	0.01%	1.47%
丙实测气象 + LightGBM	+0.3%	0.00%	1.14%
甲' 预报气象 + Persistence	-3.0%	0.18%	0.43%
甲' 预报气象 + 线性回归	-3.0%	0.26%	0.53%

+0.3% (丙 LightGBM), 节省 0.00%; 把多报单价换成现货出清上限 1.2 元/kWh 再扫, 最优偏置落到 -3% 的扫描边界, 节省也不过 1.14%。原因不难想见——两个方向的单价只差 6%, 靠挪动整体偏移量赚不回来。真正省钱的是换信息源而非调偏置: 同样这 85 天里, 甲' 的总代价 777.69 万元, 丙 LightGBM 只有 222.59 万元, 省 71.4%。

一处必须交代的口径局限: 表 13 里的 δ 是在测试期上扫出来的, 工程上属于拿测试数据调参, 会高估收益; 真实部署应该用独立的滚动校准窗口按日更新 δ 。本节也只统计了方向性偏差, 没有考虑偏差的时间累计效应 (例如连续多时段少报会不会触发不同的调度规则)。

4 结论

本文基于河北十座光伏电站的公开数据集 PVOD (271968 条、15 分钟粒度), 比较了「同时刻站内气象可得」「同时刻仅有数值天气预报」「仅历史观测可用」以及「同时刻气象与历史观测兼有」四种信息条件下的光伏短时出力预测效果, 并检验了结论的跨站可迁移性, 最后把预测误差按方向拆开、按真实电价折算成工程代价。主要结论有八点:

1. 信息条件比模型选择更决定精度。同时刻实测气象加历史观测时, 最优 MAE 为 1.4942%; 只去掉同时刻气象 (设定乙) 即升至 2.2821%; 把同时刻实测气象换成数值天气预报 (设定甲') 则为 4.8725%, 约为实测条件下的两倍。可见接入一条实时气象实测, 比换更复杂的模型更划算。
2. 在最有利条件 (设定丙) 下, 表现最好的竟是线性回归, 而非任何树模型: MAE 1.4942%、 R^2 0.9849, 优于第二名的 LightGBM 8.8%、优于 Persistence 基线 41.74%。专门做的恒等映射检验给出了机制解释——Persistence 本质是硬编码的 $P(t) = 1.0 \times P(t-1)$, 线性回归能学到接近 1 的系数 (十站平均 0.9788) 从而复现它, 而随机森林只能输出叶内均值, 单独使用该特征时反而比 Persistence 差 22.90%。这提示在含强自回归项的预测任务中, 线性基线必须与树模型并列比较。
3. 模型增益高度依赖天气动态。辐射突变 $30 \sim 60 \text{ W/m}^2$ 与超过 60 W/m^2 时降幅分别为 14.54% 与 17.90%, 而辐射平稳 ($< 10 \text{ W/m}^2$) 时段随机森林反而比 Persistence 差 163%。Persistence 是平稳天气下的天然强基线, 实际使用宜按辐射突变强度切换预测策略。
4. 同时刻气象的贡献不可被历史信息替代: 设定丙中把 6 个同时刻气象变量整组删除后, MAE 恶化 61.49%。相反, 气温、气压、风速等次要气象因子删掉后误差几乎不变 (0.19%),

时刻编码的贡献也只有 0.09%。但这是信息冗余，不代表温度对光伏没有物理影响。

5. 针对研究问题一——复杂模型并不必然更好。把 LSTM 放进与树模型完全相同的条件下，它在四个设定上**全部落后**：设定甲 3.1467 对最优树模型 2.4738（差 27.2%），设定丙 3.1624 对线性回归 1.4942（差 111.6%），设定乙里甚至输给完全不需要训练的 Persistence 基线 61.6%。训练代价上，单站 LSTM 约需 9.6 秒，是线性回归（0.003 秒）的三千余倍，精度却更差。本文给出三点解释：本任务的出力与同时刻辐射近似瞬时映射，几乎不需要长程记忆；每站 1~3.3 万条记录对神经网络偏小；且夜间零出力样本占 49.07%，与白天的规律完全不同，LSTM 必须用一套权重同时学会两种模式。这说明在这类表格型回归任务上，先把朴素基线与树模型做到位，比直接上深度模型划算。
6. 针对研究问题二——跨站迁移值得做，而且最佳做法在三类模型上是一致的，都是**多站联合训练**：树模型上降低误差 14.61%（8/10 站）与 4.11%（6/10 站），LSTM 上降低 36.15%（10/10 站），各自都是本组方案里最优的。两者的差别只出现在「预训练 + 微调」上：树模型上无效甚至有害（-0.36% 与 -11.81%），因为它只能在既有的 500 棵树上继续加树、改不动旧结构；LSTM 上则有效（18.01%、7/10 站），因为梯度会流回全部权重，预训练学到的结构可被按需重写。换第二棵树（XGBoost）复跑后，三个策略上两类树模型的方向全同，说明上述判据不是某一个库的偶然，而「收益大小会随实现浮动」（同一策略上 14.61% 与 4.11% 相差十余个百分点）才是需要交代的界限。此外 LSTM 上「预训练初始化后按常规步长训满」只得 28.96%，不如多站联合的 36.15%，说明预训练给出的起点会被后续训练覆盖，需要在少轮数、小步长下才保得住。注意 LSTM 的绝对误差仍全面高于树模型，其「提升幅度大」主要源于起点低、可提升空间大。
7. 零样本迁移在两类模型上都不宜直接使用：树模型平均变差 68.11%、仅 3/10 站有效；LSTM 平均变差 61.45%、同样仅 3/10 站有效。两者都指向同一结论——不校准地搬用别站模型风险很大，区别只在神经网络对输入分布的偏移更敏感。真正有效的是把别站数据作为**训练素材**而非**现成模型**来使用。
8. MAE 的对称性，与工程成本的非对称性，是可以量出来对账的。按河北南网真实电价折算（弃光 0.3433 元/kWh、缺额 0.3644 元/kWh），十站测试期 85 天的代价以两个设定为例：设定甲' 以**多报**为主（561.22 万元对 216.47 万元，2.6 倍），设定丙则以**少报**为主（148.37 万元对 74.22 万元，2.0 倍）——换一个信息源就把风险的主要方向整个翻了过来，这是任何对称指标都看不出来的。而且少报集中在 600 ~ 1000 W/m² 的强辐照时段（占全部少报电量的 38%），恰好是出力最大、最容易装不下的时段，弃光风险正落在这里。本文还试过一种更省事的优化——给预测整体加一个常数偏置，主口径下几乎零收益（≤ 0.26%），改用现货出清上限 1.2 元/kWh 计价也只省 1.14%，而换信息源能省 71.4%：对这类任务，事后调偏置不值得花力气，该花的功夫在把气象数据接对。

工程应用含义。预测精度最终要落到电网运行的代价上，而这个代价是有方向的：同样的误差大小，往哪个方向偏，后果并不一样。光伏电站需要按规定向调度上报功率预测曲线，调度据此决定常规机组的开机组合与旋转备用容量 [3]。

少报（预测值低于实际出力）主要损失的是电量。调度按偏低的预测多开了常规机组，实际

光伏却发得更多，系统出现出力过剩；而火电机组受最小技术出力约束，不能无限制往下压，多余的光伏电量往往只能弃掉，结果就是清洁电力被白白浪费、消纳率下降。

多报（预测值高于实际出力）主要损失的是金钱。调度按偏高的预测压减了常规机组，实际光伏发不出来，系统出现功率缺额，只能靠旋转备用、储能放电或快速启停机组临时顶上，这部分电量的成本远高于正常发电，严重时还会威胁频率稳定，并按并网考核规则产生偏差考核费用。

两个方向都不可忽略，且后者的单位代价通常更高——少掉的电「不值钱」，临时补上的电「很贵」。

这个非对称性不是嘴上说说，第 3.12 节已经把它量化了对账：按河北南网的真实电价把十站测试期的误差折算成钱，设定甲' 花掉 777.69 万元而其中 72% 是**多报**造成的，设定丙花掉 222.59 万元而其中 67% 是**少报**造成的。两个设定的 MAE 相差约 3 倍（4.87% 对 1.64%），但真正决定「钱花在哪一边」的，是误差偏向哪一侧、以及偏向的那侧单价有多高。因此工程上报告误差时，只给一个 MAE 是不够的，至少应该同时给出偏置（bias）与两侧的代价。

把这条链条再往上推一层，就接到「双碳」目标上：预测越不准，调度越不敢少留备用，系统就必须在光伏大发时段也维持一批随时可上调的火电容量兜底，这部分容量即使大部分时间闲置，也要保持热态、持续产生排放；反过来，把预测误差压下去，一头能减少这种「为防不确定而多留的火电」，另一头能减少弃光、提高清洁电量的占比，两边都直接服务于碳减排。说白了，预测越准，电网敢为不确定性少留的那部分火电就越多。

本文的数字可以给出一个直观的量级。十站总装机 193.6 MW（平均单站 19.36 MW，取自数据集配套元数据）：设定甲接入站内实测气象时 MAE 为 2.4738%，相当于每个 15 min 断面平均有约 4.79 MW 的偏差需要靠备用或调节手段去填（单站约 0.48 MW）；若改用数值天气预报（设定甲'），误差升到 4.8725%，同一数字变为约 9.43 MW（单站约 0.94 MW），二者相差约 4.64 MW。这 4.64 MW 就是「接一条站内实测气象」所对应的备用缺口规模，说明第 3.2 节那几个百分点在工程中是有具体功率含义的。

落到实际部署上，本文结果给出四条建议：一是若电站配有气象站，应优先把实时辐射数据接入预测系统，其收益远大于升级算法；二是预测策略宜按天气动态分档——云层扰动时段交给机器学习模型，晴朗平稳时段直接用 Persistence 反而更稳，还能省下算力；三是新建电站数据不足时，把周边已运行电站的数据**混合进来联合训练**是低成本且有效的做法，但不要把别站训好的模型直接拿来用（第 3.8 节显示零样本迁移在三类模型上都是负收益）；至于能降多少，第 3.10 节的复现说明它取决于所用的树引擎与超参，应实测一次再定预期，不宜照抄本文的百分比；四是选型上不必盲目追求深度模型，本文任务里 LSTM 的精度与训练代价全面劣于树模型与线性回归，先把线性基线与树模型做扎实更划算。

本文存在六点局限：一是仅使用 PVOD 一份数据集的一年记录，虽含十座电站，但地域集中于河北，结论能否推广到其他气候区未经验证；二是未做超参数搜索，模型参数取固定值（100 棵、学习率 0.1），最优模型可能尚未被找到；三是 LSTM 部分只试了单一网络结构与固定轮数（单站对照 30 轮、迁移实验 15 轮），未搜索层数、隐藏单元与学习率，其绝对误差也高于树模型，故该组实验只用于比较各方案的相对次序与迁移规律，不宜当作精度上限；四是 station04 的容量登记与 station09 的限发问题虽已指出，但本文未做进一步的数据修正，相关站的结论需谨慎对待；五是十座电站同处河北、气候背景相近，这会让跨站迁移显得更容易奏效，收益能否同样出现在气候差异更大的区域，尚待验证；六是第 3.12 节的代价折算用的是公开电价与「全

额兑现」的上界假设，没有接入实际的调度仿真，真实弃电率与备用调用量取决于电网当时的运行方式与断面约束，本节数值只能用于判断两个方向的数量级关系，不宜当作电站的真实账单。后续工作可在多气候区数据上验证本文结论，并尝试在辐射突变临近时引入更长的滚动窗口，以及把本节的分方向统计接到滚动预测（day-ahead）的考核口径上。

参考文献

参考文献

- [1] J. Antonanzas, N. Osorio, R. Escobar, R. Urraca, F. J. Martinez-de Pison, and F. Antonanzas-Torres. Review of photovoltaic power forecasting. *Solar Energy*, 136:78–111, 2016.
- [2] L. Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [3] R. H. Inman, H. T. C. Pedro, and C. F. M. Coimbra. Solar forecasting methods for renewable energy integration. *Progress in Energy and Combustion Science*, 39(6):535–576, 2013.
- [4] D. Markovics and M. J. Mayer. Comparison of machine learning methods for photovoltaic power forecasting based on numerical weather prediction. *Renewable and Sustainable Energy Reviews*, 161:112364, 2022.
- [5] Rambo. Ningxia 2019 photovoltaic power generation dataset, 2025. 15 分钟粒度，2019 年全年，宁夏光伏电站.
- [6] S. Sobri, S. Koochi-Kamali, and N. A. Rahim. Solar photovoltaic generation forecasting methods: a review. *Energy Conversion and Management*, 156:459–497, 2018.
- [7] M. Yang, M. Zhao, D. Liu, M. Ma, and X. Su. Improved random forest method for ultra-short-term prediction of the output power of a photovoltaic cluster. *Frontiers in Energy Research*, 9:749367, 2021.
- [8] Tiechui Yao, Jue Wang, Haoyan Wu, Pei Zhang, Shigang Li, Yangang Wang, Xuebin Chi, and Min Shi. A photovoltaic power output dataset: Multi-source photovoltaic power output dataset with python toolkit. *Solar Energy*, 230:122–130, 2021.
- [9] Tiechui Yao, Jue Wang, Haoyan Wu, Pei Zhang, Shigang Li, Yangang Wang, Xuebin Chi, and Min Shi. Pvod v1.0: A photovoltaic power output dataset, 2021. 河北十座光伏电站，15 分钟粒度，271968 条记录，MIT 协议.
- [10] 河北省发展和改革委员会. 河北南网深化新能源上网电价市场化改革实施方案, 2025. 存量项目机制电价按河北南网现行燃煤发电基准价 0.3644 元/千瓦时执行；冀北电网为 0.372 元/千瓦时.

- [11] 河北省发展和改革委员会. 河北南部电网电力现货市场连续结算试运行工作方案 (2025 年)
, 2025. 2025-03-01 起连续结算试运行, 电能量申报与出清限价均为 0 1200 元/兆瓦时.